



Professor: Renan Gomes Vieira

Equipe

- Igor Santana Sampaio
- Jorge Roniel de Paula Souza
- Luis Eduardo Martins Barbosa
- Victor Lopes Mendes

Trabalho Final Ciência dos Dados

Aprendizagem de Máquina

Sobre os dados:

Este conjunto de dados contém vários indicadores de saúde e fatores de risco relacionados a doenças cardíacas. Parâmetros como idade, gênero, pressão arterial, níveis de colesterol, hábitos de fumo e padrões de exercício foram coletados para analisar o risco de doenças cardíacas e contribuir para pesquisas em saúde. O conjunto de dados pode ser utilizado por profissionais de saúde, pesquisadores e analistas de dados para examinar tendências relacionadas a doenças cardíacas, identificar fatores de risco e realizar diversas análises relacionadas à saúde.

Desafios encontrados:

No desenvolvimento deste estudo, foram enfrentados desafios significativos que impactaram a condução da pesquisa. A primeira dificuldade consistiu na seleção criteriosa dos modelos de aprendizado de máquina, uma vez que a literatura oferece uma vasta gama de algoritmos com comportamentos distintos frente a dados clínicos. Determinar quais classificadores seriam mais adequados para capturar a complexidade das patologias cardíacas exigiu uma análise profunda das características de cada método.

Adicionalmente, a implementação e estruturação do código representaram um obstáculo técnico relevante. A construção de um fluxo de trabalho robusto, que integrasse de forma eficiente as etapas de pré-processamento, a execução das rodadas de validação cruzada (K-Fold) e a aplicação rigorosa dos testes estatísticos, demandou um esforço considerável para garantir a reprodutibilidade dos experimentos e a integridade dos resultados obtidos.

Aprendizado Adquirido:

O desenvolvimento deste estudo trouxe aprendizados importantes a partir das dificuldades enfrentadas. A necessidade de selecionar modelos de aprendizado de máquina diante da diversidade de algoritmos disponíveis evidenciou a importância de uma análise crítica e fundamentada para compreender suas limitações e potencialidades frente a dados clínicos complexos.

Além disso, a implementação de um fluxo de trabalho robusto mostrou que a organização e a integração cuidadosa das etapas de pré-processamento, validação cruzada e testes estatísticos são essenciais para assegurar a reprodutibilidade e a confiabilidade dos resultados, reforçando que rigor metodológico e competência técnica caminham juntos na pesquisa científica.

Regressão

Sobre os dados:

Conjunto de dados tirado da bolsa de valores do Yahoo Finance sobre as ações do Itaú ITUB3.SA

Desafios encontrado:

Prevenção de vazamento de dados(Data Leakage), a maior dificuldade inicial foi identificar e corrigir o vazamento de dados. Inicialmente, o modelo utilizava variáveis como "Máxima" e "Mínima" do dia corrente para prever o fechamento do mesmo dia. Isso gerava métricas ilusórias (R^2 de 1.00), pois o modelo recebia "gabaritos" do futuro. O desafio foi reestruturar a lógica para usar apenas dados do passado (D-0, D-1) para prever o futuro (D+1).

Definição da estratégia de validação cruzada, aplicar a validação cruzada tradicional (K-Fold com shuffle) mostrou-se inadequada para séries temporais, pois misturava dados futuros no treinamento de dados passados. A dificuldade foi implementar o TimeSeriesSplit, garantindo que o modelo fosse treinado e testado respeitando estritamente a ordem cronológica (janelas deslizantes de tempo).

Interpretação de métricas negativas em modelos complexos, houve dificuldade em entender por que modelos robustos como Random Forest e XGBoost apresentaram desempenho muito inferior (R^2 negativo) comparado a modelos lineares simples. Foi necessário investigar a natureza desses algoritmos para compreender sua incapacidade de extrapolação em tendências de alta.

Aprendizado Adquirido:

Engenharia de atributos temporal (Lag Features), aprendemos que, em séries temporais, a relação entre as variáveis deve ser deslocada. A criação de colunas de Target com shift(-1) e o alinhamento correto dos índices foram cruciais para que o modelo aprendesse a prever o dia seguinte baseando-se apenas nas informações disponíveis hoje, simulando um cenário real de trading.

Capacidade de extrapolação dos modelos, o projeto evidenciou uma diferença teórica importante: modelos baseados em árvore (como XGBoost e Random Forest) não conseguem prever valores fora da escala vista no treino (não extrapolam tendências). Já modelos lineares (como Ridge Regression) conseguem traçar uma tendência contínua, o que os tornou superiores neste cenário específico de alta do ativo.

Métricas de avaliação (RMSE vs R^2), consolidamos o entendimento de que o R^2 mede a explicação da variância, enquanto o RMSE oferece uma visão prática do erro na moeda do ativo. Aprendi a utilizar o `neg_root_mean_squared_error` dentro do GridSearch para otimizar os hiperparâmetros focando na minimização do erro real.

NLP

Sobre os dados:

Este conjunto de dados contém diversos registros de interações e preferências de usuários em relação a obras cinematográficas. Parâmetros como títulos de filmes, gêneros, avaliações numéricas e etiquetas de conteúdo (tags) foram coletados para analisar padrões de consumo de mídia e contribuir para pesquisas em sistemas de personalização. O conjunto de dados pode ser utilizado por cientistas de dados, pesquisadores de inteligência artificial e analistas de sistemas para examinar tendências no setor do entretenimento, identificar perfis de preferência e realizar diversas análises relacionadas a algoritmos de recomendação.

Desafios encontrados:

O dataset original continhas diversos atributos que não contribuía para a nossa análise de NLP proposta, como IDs, nomes de diretores e URLs de imagens etc. Um dos desafios iniciais foi realizar a seleção de atributos que realmente eram relevantes, focando no conteúdo mais textual, como reviews e pegando também a nota dos críticos para usarmos mais tarde como indicador do que tem review boa e ruim. Em seguida, garantimos o tratamento de dados faltantes (NaN) e strings vazias, que poderiam comprometer a execução dos nossos algoritmos.

Outro desafio encontrado foi o desbalanceamento da classe "Fresh". Ao rodar os primeiros experimentos, a matriz de confusão revelou que o modelo apresentava um viés, classificando errado muitas críticas negativas como positivas. Vencemos esse desafio aplicando a técnica de random undersampling, igualando as amostras das classes "Fresh" e "Rotten", o que resultou em um modelo muito mais equilibrado e confiável.

Por fim, enfrentamos dificuldades no ajuste de hiperparâmetros. Entender como cada impacto de parâmetro no espaço de busca do Grid Search foi desafiador. Foi necessário entender que a inclusão de bigramas era essencial para capturar o contexto de expressões de negação (ex: "not good"), apesar de aumentar a complexidade do modelo.

Aprendizados adquiridos:

Com o desenvolvimento deste projeto, aprendemos que uma acurácia alta pode enganar se o modelo não for capaz de distinguir bem as classes individualmente. A análise da matriz de confusão, com as métricas de Precision, Recall e F1-Score, se tornou nossa principal ferramenta para validar a qualidade real do classificador e garantir que ele não estivesse apenas "chutando" a classe mais frequente.

O uso de WordClouds foi um aprendizado valioso para a explicabilidade do modelo. Inicialmente, as nuvens continham termos genéricos que não nos davam valor visual. Ao adicionarmos elas nas stopwords, conseguimos validar que o modelo estava de fato focando em termos relevantes e adjetivos que expressam opiniões, tornando a visualização muito mais clara e interpretável.